



Makine Öğrenmesi Destekli Anlamsal Ürün Arama Motoru

BIL 496
İkinci Buluşma

Simge Sarıçayır

Proje Danışmanı: Fatih Erdoğan Sevilgen
Aralık 2019





- Proje nedir?

E-ticaret siteleri için makine öğrenmesi destekli anlamsal ürün arama motoru.

- Günümüzde yaygınlaşan e-ticaret sitelerinde doğru ürün listeleme ile satışın artırılması.
- Satın alınmak istenen ürünün arama sonucunda doğru sırada bulunamaması.
- Yapılan listelemede istenen ürünün yer almaması ya da anlamsal olarak alakasız şeylerin listelenmesi

- Eğitilen Word2Vec modeli kullanılarak arama yapılan kelimelere karşılık modelde en yakın kelimeler bulundu ve ürün listesinden bu kelimeleri içeren ürünler listelendi.
- Modelin iki kelime arasındaki benzerlik oranını vermesi ile ürün isimleri üzerinde bu benzerlik oranı kullanılarak sıralamada puanlama yapıldı.
- İki farklı e-ticaret sitesinden elde edilmiş olan ürün açıklama verileri ve arama motorunun gerçekleştiği ürün isimleri birleştirilerek başka bir Word2Vec modeli eğitildi.
- Oluşturulan diğer model ile aynı kelimeler üzerinde karşılaştırma yapıldığında ilk oluşturulan model daha iyi sonuç verdi.



- Ürün isimleri Google'da aratıldığında gelen sonuçlardan ilk 5 sitedeki bilgiler çekilerek daha geniş bir eğitim verisi elde edildi.
- Toplanan verilerin temizlenmesi ve ön işleme yapılmasından sonra bu veri kullanılarak Word2Vec Cbow modeli eğitildi.
- Model arama motoru geliştirilmesi için kullanıldı.
- Arama motoru için arama kelimesine karşılık ürün isimleri verisi bir sanal marketin log dosyasından çıkarıldı.
- Elde edilen veri hem test hem de makine öğrenmesi için kullanıldı.





- 

Kullanıcıların arattığı kelimelerle satın almayı tercih ettikleri veriler kullanılarak arama motoru test edildi.

4134 tane ürün-arama kelimesi verisi kullanıldı.

Bulunma Sırası	Sayısı
1	1000
2	437
3	283
4	224
5	188
6	134
7	115
8	118
9	84
10	103

2687 tanesi ilk 10'da
gelirken 1447 tanesi için ilk
10 sırada sonuç alınamadı.

Bu durumda 0.65 oranında
başarı sağlandı.



- Arama motorunu test etmek için kullanılan veri ile makine öğrenmesi tekniklerinden sınıflandırma denendi.
- Sınıf olarak ürün isimleri , öğrenilecek veri için de arama kelimesinin Word2Vec modelinden elde edilen 300 boyutlu vektör kullanıldı.
- Verinin %20'si test , %80'i eğitim için kullanıldı.



Bir sınıfın 10 veya 10'dan fazla üyesi varsa veri setine eklenerek eğitim gerçekleştirildi.

Algoritma	Doğruluk Oranı
Lojistik Regresyon(Logistic Regression)	0.88
En Yakın Komşu (K Nearest Neighbor)	0.83
Karar Ağaçları (Decision Trees)	0.87
Gaussian Naive Bayes	0.75
Destek Vektör Makineleri (Support Vector Machines)	0.79



- Kelime köklerini bulmak için daha iyi sonuçlar veren kütüphane ile test yapılacaktır.
- Yanlış yazım durumu için aratılan kelimeler Word2Vec modelinde yoksa Edit Distance algoritması ile modeldeki olası kelime için sonuçlar bulunacaktır.
- Sınıflandırma için veri toplanacaktır ve model daha çok veri ile tekrar eğitilecektir.
- Sınıflandırıcı kullanılarak kullanıcı seçimleri sayesinde ürünlerin listelenmesinde daha iyi sıralama elde edilecektir.



Başarı Kriterleri

- Arama kelimelerine karşılık listelenen ilk 10 ürünün test ve eğitim için kullanılan verilerdeki aynı arama kelimesine karşılık satın alınan ürünlerin en az 5'ini içermesi.(düzeltme : %90'ını içermesi)
- Kullanıcıdan toplanan verilere bakıldığında arama kelimesine karşılık satın alınan ürünlerin listelemedeki sıralarının toplamının ürünün sepete eklenme sayısına bölündüğünde 5'ten küçük bir değer elde edilmesi.
- Listelenen ilk 10 ürün adının içerdiği kelimelerden en az birinin arama kelimesi ile word2vec modelindeki benzerlik oranının %70'in üzerinde olması.



1. T. Mikolov, K. Chen, G. Corrado, J. Dean, "Efficient Estimation of Word Representations in Vector Space", arxiv.org., September 2013.
2. A McCallum, K Nigam, J Rennine, K Seymore - IJCAI, 1999 – Citese

